


Od dystansu po zaufanie:

Analiza opinii użytkowników o interakcjach z chatbotami AI

From Distance to Trust: Analysis of User Opinions on Interactions with AI Chatbots

Kinga Kopczyk | 522122

Przeptyw danych w projekcie



Pytania badawcze

1. Czy **afekt** w komentarzach użytkowników **różni się** w zależności od **kategorii chatbota**?
2. Jakie **wzorce tematyczno-afektywne** powtarzają się w opiniach?
3. Czy **sentyment** wobec chatbotów **zmienił się w czasie**?
4. Czy da się **przewidzieć ocenę gwiazdkową** recenzji na podstawie tekstu wypowiedzi?

Kołowy model afektu Russella


1. Czy afekt w komentarzach użytkowników różni się w zależności od **kategorii chatbota**?



Model Afektu Russella

Mapowanie wyników analizy opinii systemem GoEmotions

1. Czy afekt w komentarzach użytkowników różni się w zależności od kategorii chatbota?



Test Kruskala-Wallisa – Walencja

test statystyczny na istotność różnic w wymiarze walencji pomiędzy kategoriami

→ $p < .001$ – różnice statystycznie istotne

NRC VAD:	H = 2767	$\epsilon^2 = 0,020$
VADER:	H = 3467	$\epsilon^2 = 0,025$
GoEmotions:	H = 4838	$\epsilon^2 = 0,035$

→ efekt (ϵ^2) różnic jest mały/średni, ale spójny we wszystkich trzech modelach

Test Kruskala-Wallisa – Pobudzenie

test statystyczny na istotność różnic w wymiarze pobudzenia pomiędzy kategoriami


→ $p < .001$ – różnice statystycznie istotne

NRC VAD:	$\epsilon^2 = 0,002$	efekt pomijalny
VADER:		nie dotyczy
GoEmotions:	$\epsilon^2 = 0,011$	efekt mały

→ kategorie różnią się głównie walencją, a różnice w pobudzeniu są pomijalne

Mapowanie wyników analizy opinii z leksykonem NRC VAD

1. Czy afekt w komentarzach użytkowników różni się w zależności od **kategorii chatbota**?



Test Kruskala-Wallisa – Walencja

test statystyczny na istotność różnic w wymiarze walencji pomiędzy kategoriami

→ $p < .001$ – różnice statystycznie istotne

NRC VAD: H = 2767 $\varepsilon^2 = 0.020$

VADER: $H = 3467$ $\varepsilon^2 = 0,025$

GoEmotions: H = 4838 $\epsilon^2 = 0,035$

→ efekt (ε^2) różnic jest mały, ale spójny we wszystkich trzech modelach

Test Kruskala-Wallisa – Pobudzenie

test statystyczny na istotność różnic w wymiarze pobudzenia pomiędzy kategoriami

→ $p < .001$ – różnice statystycznie istotne

NRC VAD: $\varepsilon^2 = 0.002$ efekt pomijalny

VADER: nie dotyczy


GoEmotions: $\epsilon^2 = 0,011$ efekt mały

→ kategorie różnią się głównie walencją, a różnice w pobudzeniu są pomijalne

Model Afektu Russella

Mapowanie wyników konsensu VADER+NRV VAD+GoEmotions

1. Czy afekt w komentarzach użytkowników różni się w zależności od **kategorii chatbota**?



Test post-hoc Dunna z korektą Bonferroniego
Nieparametryczny test statystyczny ujawniający największą i najmniejszą różnicę pomiędzy parami kategorii chatbotów z korektą dla wielokrotnych porównań

♦ **Największa różnica walencji:**
Chatboty **Edukacyjne** (największa) ↔ **Uniwersalne** (najmniejsza)

♦ **Najmniejsza różnica walencji:**
Chatboty **Terapeutyczne** ↔ **Wirtualni Asystenci**


Jednoczynnikowa analiza MANOVA
Wielowymiarowa analiza wariancji dla walencji i pobudzenia łącznie

Wilks' λ = 0,979
F = 491,21
p < .001





→ wizualne separacje kategorii na Circumplex są statystycznie istotne

Ranking walencji wśród 16 aplikacji

1. Czy afekt w komentarzach użytkowników różni się w zależności od **kategorii chatbota**?







(2. Jakie wzorce tematyczno-afektywne powtarzają się w opiniach?)



N-gramy według kategorii

2. Jakie wzorce tematyczno-afektywne powtarzają się w opiniach?



Zbiory tematyczne BERTopic

Zatytułowane przy użyciu Claude Anthropic


2. Jakie wzorce tematyczno-afektywne powtarzają się w opiniach?



Trend sentymentu

Walencja na przestrzeni lat z podziałem na kategorie chatbotów

3. Czy sentyment wobec chatbotów **zmienił się w czasie?**



Korelacja rang Spearmana


Nieparametryczny test na statystyczną istotność i kierunek trendów walencji w czasie

- Chatboty **ogólne**: tylko VADER istotny ($\rho = +0,318$, $p = .040$) — trend wzrostowy ↗
- Chatboty **terapeutyczne**: tylko NRC VAD istotny ($\rho = +0,361$, $p = .017$) — trend wzrostowy ↗
- Wirtualni asystenci**: VADER ($\rho = +0,308$) i NRC VAD ($\rho = +0,328$) — trend wzrostowy ↗
- Chatboty **Edukacyjne**: VADER ($\rho = -0,571$) i GoEmotions ($\rho = -0,468$) — trend spadkowy ▼

Trend sentymentu

Walencja na przestrzeni lat względem ogółu chatbotów

3. Czy sentyment wobec chatbotów **zmienił się w czasie?**



Korelacja rang Spearmana


Nieparametryczny test na statystyczną istotność i kierunek trendów walencji w czasie

→ statystycznie istotny trend wzrostowy według wszystkich modeli: NRC VAD (rho = 0.648, p < .001), VADER (rho = 0.505, p < .001), GoEmotions (rho = 0.455, p = .002)

Metryki klasyfikatorów

Predykcja oceny gwiazdkowej na podstawie tekstu recenzji

4. Czy da się przewidzieć ocenę gwiazdkową recenzji na podstawie tekstu wypowiedzi?




Najlepszy ranking probabilistyczny:
Gradient Boosting — All Models Combined:

AUC-ROC = 0,778
→ **ale:** wynika ze niezbalansowanych klas posiadając zerową precyzję i czułość dla klas 2★, 3★ i 4★
F1 Weighted / F1 Macro ~ 2,000



Najlepszy klasyfikator:
Logistic Regression — All Models Combined

F1 macro = 0,384
AUC-ROC = 0,756
→ jedyny model z niezerowym recall dla klas 2★ i 4★
→ najbardziej odporny na niezbalansowanie klas

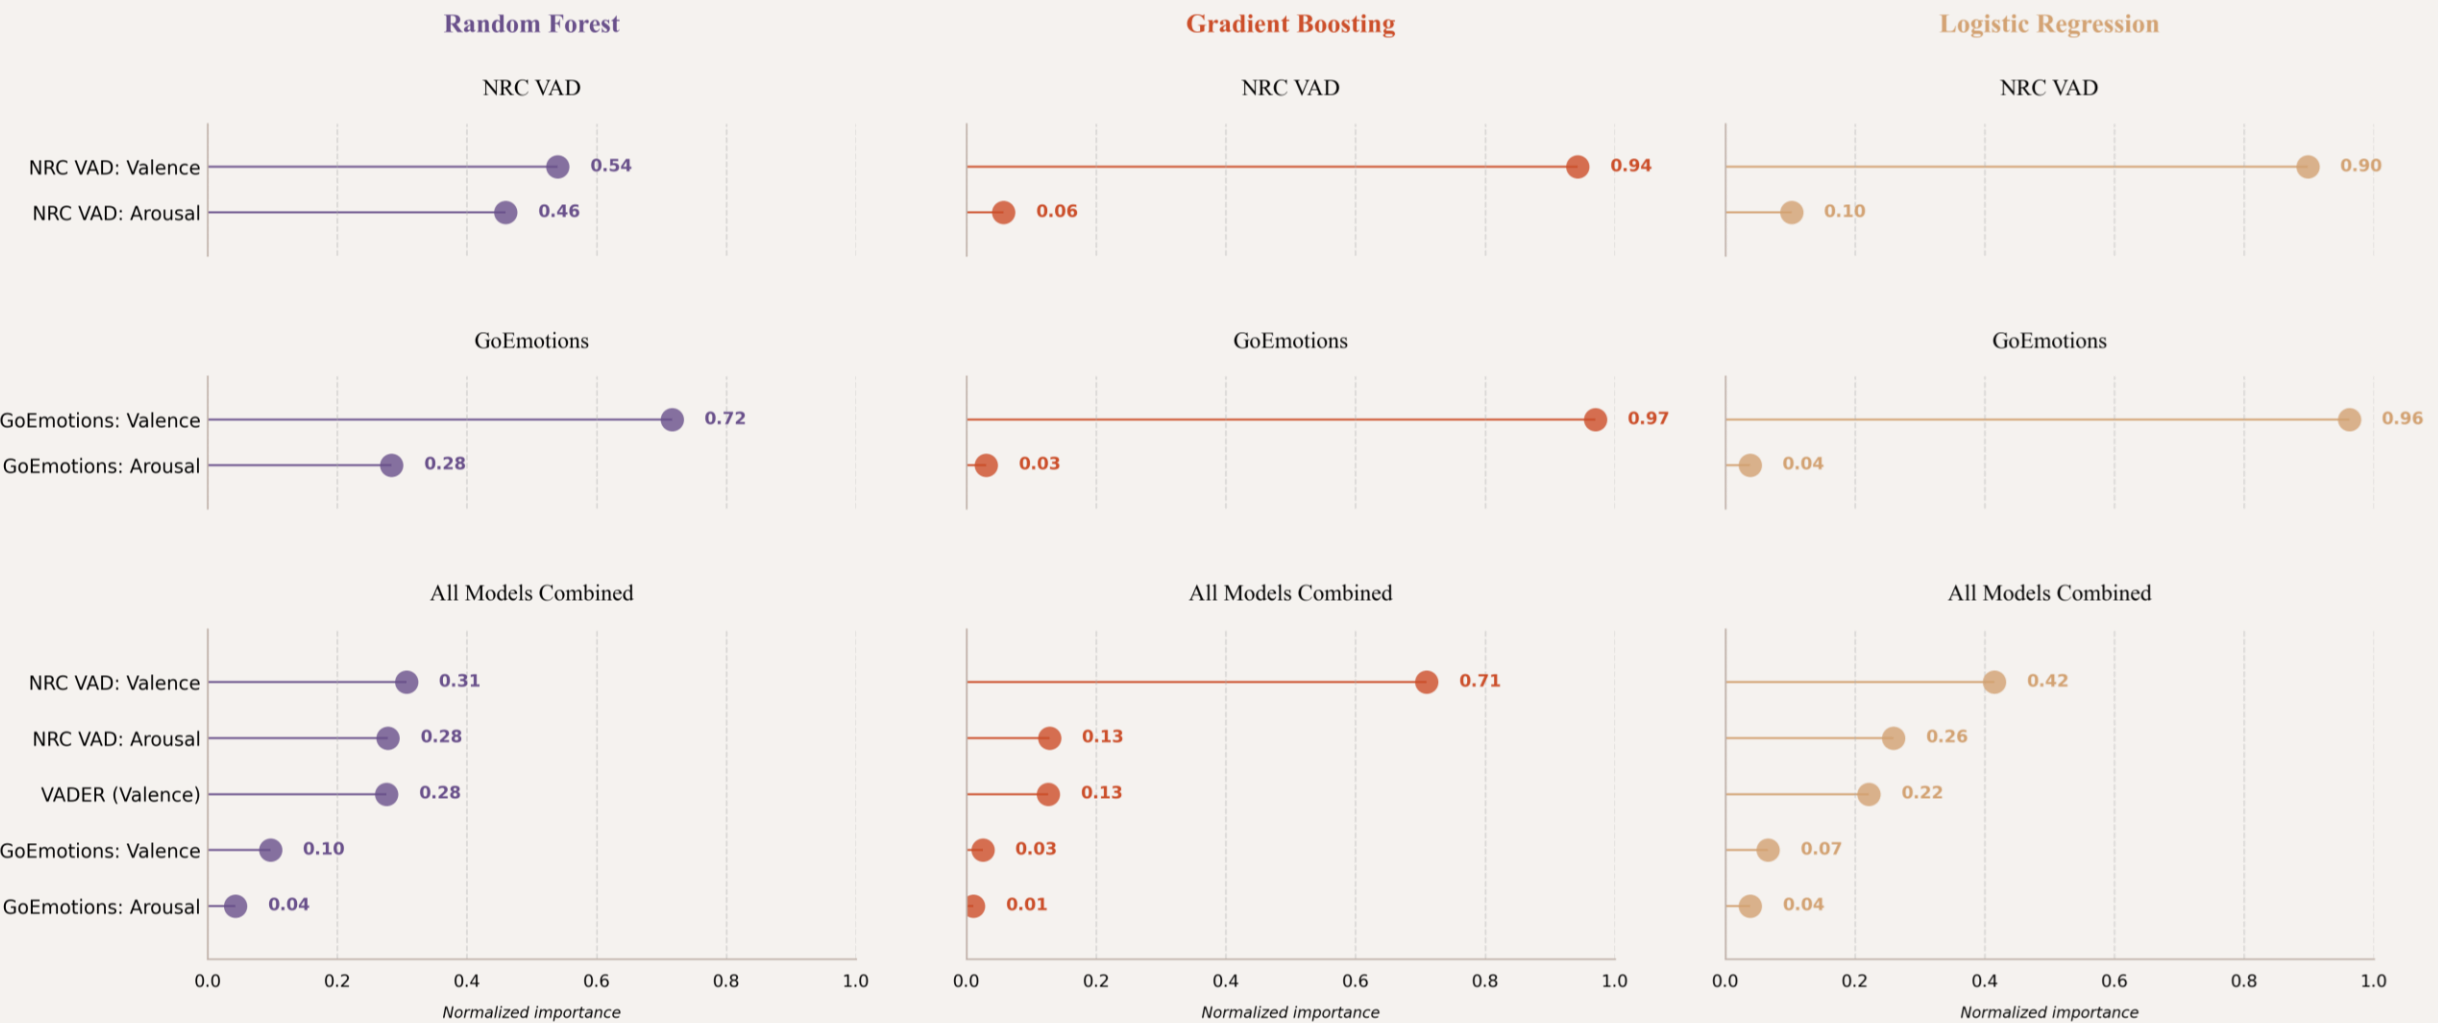


Najlepsze wykrywanie opinii 1★:
Random Forest — GoEmotions :

recall = 0,860
F1(1★) = 0,666

Istotność cech w predykcji ocen




4. Czy da się przewidzieć ocenę gwiazdkową recenzji na podstawie tekstu wypowiedzi?



Metryki klasyfikatorów

Porównanie z modelami bazowymi (konsensus sentymentu)

4. Czy da się przewidzieć ocenę gwiazdkową recenzji na podstawie tekstu wypowiedzi?



Wszystkie 3 analizowane klasyfikatory przekraczają oba modele bazowe we wszystkich metrykach

→ Logistic Regression, mimo najniższej dokładności (0,55), zbliżonej do wyniku Majority Class Baseline, osiąga najwyższe F1 Macro (0,38), będąc tym samym najlepszym modelem pod względem równomiernego traktowania klas.


→ Wysoka dokładność Gradient Boosting (0,71) wynika z dominacji klasy 5★ w danych

→ F1 Macro (0,32) ujawnia, że model ten radzi sobie słabiej z rzadszymi klasami niż pozornie prostszy klasyfikator Logistic Regression.

→ AUC-ROC, odporna na niezbalansowanie klas, wykazuje znaczącą przewagę klasyfikatorów nad modelami bazowymi. Dobrze rankinguje prawdopodobieństwo przypisania właściwej klasy, ale gorzej wypada w klasach rzadkich.

Bias w predykcji klasyfikatorów

4. Czy da się przewidzieć ocenę gwiazdkową recenzji na podstawie tekstu wypowiedzi?



Podsumowanie projektu

1. Czy afekt w komentarzach użytkowników różni się w zależności od **kategorii chatbota**?

Tak, kategoria chatbota istotnie różnicuje afekt użytkowników, przede wszystkim **na wymiarze walencji**, co potwierdzają trzy niezależne modele i testy statystyczne

2. Jakie **wzorce tematyczno-afektywne** powtarzają się w opiniach?

Wzorce tematyczno-afektywne są **wyraźnie specyficzne dla kategorii**: użytkownicy chatbotów terapeutycznych piszą o relacjach i emocjach, edukacyjnych — o błędach matematycznych i reklamach, uniwersalnych — o eksploracji narzędzia, kodowaniu i pracy zawodowej, a wirtualnych asystentów — o rutynowych zadaniach i inteligentnych systemach pomocy.

3. Czy sentyment wobec chatbotów **zmienił się w czasie**?

Sentyment istotnie zmieniał się w czasie i był reaktywny na zewnętrzne wydarzenia, przy czym kategoria edukacyjna jako jedyna wykazała konsekwentny trend spadkowy.

4. Czy da się **przewidzieć ocenę gwiazdkową** recenzji na podstawie tekstu wypowiedzi?

Ocena gwiazdkowa jest **przewidywalna tylko w ograniczonym stopniu**, co świadczy o tym, że standaryzowana ocena i emocje zawarte w tekście opinii to różne zmienne. Jeśli zatem celem analiz jest pełne poznanie opinii użytkowników na temat interakcji z chatbotami sztucznej inteligencji, te **formy recenzji warto traktować jako komplementarne, a nie zamienne**.